

LABORATÓRIO 02

Assistentes de IA vs. codificação manual

Um experimento controlado sobre produtividade, qualidade funcional e estrutura do código

Identificação	Informação
Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Professor	Danilo Maia
Equipe	Flavio de Souza Ferreira Jr · Luidi Cadete Silva
Turma	6º período · Noite
Data	23 de setembro de 2026

Repositório e dados reproduzíveis: github.com/flaviojuniordev/Software-Measurement-and-Experimentation

Resumo executivo

Nos oito trials observados, o uso do OpenAI Codex reduziu fortemente o tempo de resolução: a mediana caiu de 1.683,5 s para 47,2 s, com vantagem para IA nos quatro pares. Todos os trials terminaram com 100% dos testes de aceitação passando, portanto não houve diferença funcional detectável. O código produzido com IA apresentou menor LOC e menor complexidade ciclomática em todos os pares, mas nenhuma comparação atingiu significância a 5%, principalmente pela amostra mínima de quatro pares.

Leitura correta do resultado

O efeito observado em tempo é grande e consistente, porém o teste exato de Wilcoxon bilateral produziu $p = 0,125$. Assim, o experimento oferece evidência descritiva forte no contexto avaliado, mas não autoriza uma generalização estatística ampla.

Questões de pesquisa

RQ	Pergunta	Síntese da resposta
RQ1	A IA reduz o tempo para resolver a tarefa?	Sim nos quatro pares; mediana 97,4% menor, sem significância bilateral a 5%.
RQ2	A IA reduz defeitos ao final do time-box?	Não foi possível diferenciar: ambos os tratamentos alcançaram 100% de sucesso.
RQ3	A IA altera complexidade ou duplicação?	LOC e complexidade foram menores com IA; MI e duplicação permaneceram inconclusivos.

Artefatos entregues

- Scripts de cronometragem, coleta, métricas estáticas e análise estatística.
- Quatro katas autorais com testes automatizados de aceitação.
- CSV consolidado com oito trials e CSV de métricas estruturais.
- Dashboard web com filtros, gráficos e exportação dos resultados.
- Relatório final, figuras reproduzíveis e rastreabilidade por Issues/PRs.

1. Introdução

Assistentes de IA generativa passaram a participar diretamente da implementação de software, mas ganhos percebidos nem sempre são medidos em condições controladas. Este trabalho compara codificação com e sem assistência de IA em tarefas pequenas de programação, observando produtividade, correção funcional e estrutura do código. O estudo adota o paradigma Goal–Question–Metric (GQM) [2] e princípios de experimentação em engenharia de software [1].

O objetivo é analisar o uso de um assistente de IA generativa na resolução de katas, com o propósito de comparar seu efeito frente à codificação manual, com respeito ao tempo de resolução, aos defeitos remanescentes e às métricas estáticas, do ponto de vista do grupo pesquisador, no contexto de estudantes de graduação sob time-box fixo.

1.1 Hipóteses

RQ	Hipótese nula (H0)	Hipótese alternativa (H1)
RQ1	A distribuição das diferenças pareadas de tempo é centrada em zero.	O tratamento com IA apresenta menor tempo até todos os testes passarem.
RQ2	A taxa de sucesso final não difere entre os tratamentos.	O tratamento com IA apresenta maior taxa de sucesso e menos falhas.
RQ3	As métricas estruturais não diferem entre os tratamentos.	IA altera LOC, complexidade, duplicação ou manutenibilidade.

1.2 Métricas

RQ1 usa tempo até o verde como métrica primária, mediana e IQR como resumo e censura em 35 minutos para trials sem sucesso. RQ2 usa taxa de sucesso e número absoluto de testes falhando. RQ3 usa LOC, complexidade ciclomática média por função, percentual de linhas duplicadas e Índice de Manutenibilidade (MI).

2. Metodologia

2.1 Desenho experimental

Foi empregado um desenho crossover within-subject pareado por participante e kata. Cada integrante ficou responsável por duas katas e resolveu cada uma nos dois tratamentos. Essa estratégia controla parte da variação individual, mas a repetição do mesmo problema pode gerar aprendizado entre execuções; por isso, a ordem foi registrada e tratada como ameaça à validade, sem alegar contrabalanceamento completo.

Componente	Definição operacional
Variável independente	Uso do assistente: com_ia ou sem_ia.
Variáveis dependentes	Tempo, testes aprovados/falhos, LOC, complexidade, MI e duplicação.
Unidade pareada	Participante + kata, comparada nos dois tratamentos.
Amostra	2 participantes, 4 katas, 8 trials e 4 pares.
Time-box	35 minutos por trial; insucesso seria censurado em 2.100 s.

Componente	Definição operacional
Tratamento com IA	OpenAI Codex, serviço utilizado em 16/09/2026; identificador exato do modelo não foi registrado.
Tratamento manual	Implementação sem interação com assistente de IA durante o trial.

2.2 Objetos experimentais

As tarefas foram escritas pelo grupo e pouco indexadas, reduzindo a chance de mera reprodução de soluções memorizadas. Todas possuem testes de aceitação determinísticos em pytest.

Kata	Problema	Responsável	Testes
kata_01	Agenda de calibração	Flavio	10
kata_02	Despachos do correio pneumático	Flavio	11
kata_03	Empréstimos de ferramentas	Luidi	11
kata_04	Ciclos de rega	Luidi	12

2.3 Ambiente e instrumentos

Camada	Tecnologia e versão
Linguagem	Python 3.14.7
Aceitação	pytest 8.4.2
Análise de dados	pandas 3.0.6 · NumPy 2.5.3 · SciPy 1.18.1
Visualização	Matplotlib 3.11.2 · Seaborn 0.13.2
Complexidade / MI	Radon 6.0.1
Duplicação	jscpd 4.3.0 · Node.js 26.9.0
Gestão	GitHub Issues, Pull Requests e Projects

2.4 Procedimento

- Iniciar o trial com participante, kata, tratamento e time-box de 35 minutos.
- Resolver a tarefa sob o tratamento designado e encerrar ao alcançar todos os testes ou o limite.
- Registrar timestamps, tempo até o verde, censura, testes aprovados/falhos e observações no CSV.
- Executar Radon e jscpd sobre a solução final e consolidar as métricas estáticas.
- Validar o dataset, formar pares participante–kata e executar as análises reproduzíveis.

2.5 Estratégia estatística

Devido ao tamanho reduzido e à assimetria dos tempos, as tabelas usam mediana e intervalo interquartil. O teste inferencial principal é o Wilcoxon pareado exato [3, 7], bilateral a $\alpha = 0,05$. Para interpretação prática, foram

calculadas diferenças pareadas, redução percentual, speedup e correlação rank-biserial orientada a favor da IA. A RQ3 inclui ajuste de Holm para quatro comparações, bootstrap exploratório e análise leave-one-pair-out.

Critério de decisão

$p < 0,05$ rejeita H_0 . $p \geq 0,05$ não prova igualdade: indica evidência insuficiente para rejeitar H_0 com esta amostra.

3. Resultados

3.1 RQ1 — Tempo até o verde

Os quatro pares foram mais rápidos com IA. A mediana caiu de 1.683,5 s (28 min 03,5 s) para 47,2 s, diferença mediana de -1.641,1 s. A redução percentual mediana foi 97,4% e o speedup mediano foi 38,4×. Nenhum trial alcançou o time-box.

Tratamento	n	Mediana (s)	IQR (s)	Q1–Q3 (s)	Time-box
Com IA	4	47,185	9,493	42,776–52,269	0/4
Sem IA	4	1.683,500	154,350	1.614,754–1.769,104	0/4

Teste	Estatística	p	Interpretação
Wilcoxon bilateral exato	$W = 0$	0,1250	H_0 não rejeitada a 5%.
Wilcoxon direcional exploratório	$W = 0$	0,0625	Sinal consistente, ainda acima de 5%.
Rank-biserial orientado	$r_{rb} = 1,00$	—	Todos os pares favorecem IA.




Figura 1 — Tempos pareados e distribuição bootstrap da diferença de tempo.

RQ1 · Ganho de velocidade em cada par



Figura 2 — Speedup por par; todos os valores permanecem acima de 1x.

RQ1 · Os 16 mundos possíveis sob a hipótese nula

Com quatro pares, o resultado bilateral exato e $p=0.125$; a resolucao inferencial e limitada.




Figura 3 — Distribuição exata das permutações de sinais para a RQ1.

Resposta à RQ1

No conjunto observado, IA reduziu substancialmente o tempo em todos os pares. A hipótese alternativa é apoiada descritivamente e por grande tamanho de efeito, mas H0 não é rejeitada pelo teste bilateral exato com apenas quatro pares.

3.2 RQ2 — Defeitos e sucesso funcional

Todos os oito trials terminaram verdes: foram 88 testes de aceitação aprovados e nenhuma falha final. A mediana da taxa de sucesso foi 100% em ambos os tratamentos. Como as diferenças pareadas são todas zero, o Wilcoxon não é informativo para esta RQ.

Tratamento	Trials verdes	Testes aprovados	Testes falhos	Sucesso mediano
------------	---------------	------------------	---------------	-----------------

Tratamento	Trials verdes	Testes aprovados	Testes falhos	Sucesso mediano
Com IA	4/4	44	0	100%
Sem IA	4/4	44	0	100%

RQ2 · Resultado funcional ao final do time-box

8/8 trials verdes; não houve variação observada em defeitos entre os tratamentos.



Figura 4 — Resultado funcional final: empate completo entre os tratamentos.

Resposta à RQ2


Não foi observada redução de defeitos, pois nenhum tratamento deixou defeitos detectados pelos testes de aceitação. O resultado deve ser descrito como empate funcional, não como prova de equivalência.

3.3 RQ3 — Estrutura do código

LOC e complexidade ciclomática foram menores com IA nos quatro pares. O MI teve diferenças pequenas e instáveis; a duplicação foi zero em sete das oito soluções, com um único valor de 15,49% na condição manual. Após correção de Holm, nenhuma métrica apresentou diferença estatisticamente significativa.

Métrica	Com IA mediana (IQR)	Sem IA mediana (IQR)	Dif. mediana	p	p Holm
LOC	49,0 (0,75)	65,0 (15,50)	-15,5	0,125	0,500
Complexidade média	15,167 (15,084)	20,0 (15,0)	-5,0	0,125	0,500
MI	57,687 (1,421)	57,521 (3,397)	+0,405	0,875	1,000
Duplicação (%)	0,0 (0,0)	0,0 (3,873)	0,0	1,000	1,000

RQ3 · Comparações pareadas da estrutura do código



RQ3 • Efeitos observados




Figura 7 — Tamanhos de efeito orientados a favor da IA e incerteza.

Resposta à RQ3

IA esteve associada a soluções menores e menos complexas nesta amostra. MI e duplicação não apresentam padrão robusto. Como todos os p ajustados são $\geq 0,50$, os achados estruturais são exploratórios.

4. Robustez e ameaças à validade

4.1 Verificações adicionais




Figura 8 — Sensibilidade leave-one-pair-out das diferenças estruturais.

A direção das diferenças de LOC e complexidade permanece estável ao remover qualquer par. MI e duplicação mudam mais com a exclusão de observações, confirmando que essas duas métricas não sustentam uma conclusão firme. Os intervalos bootstrap são apresentados como exploração visual, não como substitutos do teste exato.

4.2 Ameaças

Tipo	Ameaça	Mitigação / impacto residual
Conclusão	Apenas quatro pares reduzem o poder estatístico.	Testes exatos, medianas/IQR, efeitos e linguagem cautelosa; replicação necessária.
Interna	Aprendizado ao repetir a mesma kata nos dois tratamentos.	Ordem registrada; desenho reconhecido como parcialmente contrabalanceado.
Interna	Familiaridade desigual com IA, Python ou ferramentas.	Mesmo participante comparado consigo e ambiente comum de análise.
Construto	Testes aprovados não cobrem todos os defeitos possíveis.	Uso de suíte de aceitação comum; sem alegar ausência absoluta de defeitos.
Construto	Complexidade e MI resumem apenas aspectos estáticos.	LOC como controle e combinação de quatro métricas complementares.
Externa	Katas pequenas e dois estudantes limitam generalização.	Objetos autorais e documentação para futura replicação ampliada.
Instrumentação	Identificador exato do modelo de IA não registrado.	Produto e data registrados; limitação explícita para replicações futuras.

5. Processo e rastreabilidade

O trabalho foi dividido por sprint e acompanhado por Issues, branches e Pull Requests. Cada integrante produziu artefatos de código identificáveis. Os commits referenciam os números das Issues, preservando a ligação entre planejamento, implementação e resultado.

Issue	Responsável	Entregável
#12	Flavio	Cronometragem e registro de trials
#13	Luidi	Katas e testes de aceitação
#14	Luidi	Desenho e métricas estáticas
#16	Flavio	Trials das katas 01 e 02
#17	Luidi	Trials das katas 03 e 04
#20	Flavio	Análise estatística de RQ1 e RQ2
#21	Luidi	Análise de RQ3 e dashboard consolidado




Figura 9 — GitHub Project filtrado por Lab02 no encerramento da execução.

Links de auditoria: [repositório](#) · [GitHub Project](#)

6. Discussão

A principal evidência do experimento é a diferença de produtividade. Os quatro pares apontam na mesma direção, com ganho mediano de 38,4×. Em tarefas curtas, bem especificadas e verificadas por testes, o assistente produziu soluções funcionais rapidamente. Entretanto, a velocidade observada não implica que o mesmo fator se mantenha em sistemas maiores, requisitos ambíguos ou atividades com alto custo de integração.

A ausência de diferença na RQ2 tem duas leituras. Positivamente, a velocidade não veio acompanhada de falhas finais nos testes disponíveis. Por outro lado, existe efeito-teto: como todos os trials atingiram 100%, a métrica não contém variabilidade para distinguir tratamentos. Uma replicação pode incluir mutação de testes, casos ocultos ou tarefas mais difíceis para aumentar a sensibilidade funcional.

Na RQ3, a redução de LOC e complexidade acompanha o ganho de tempo e permaneceu direcionalmente estável no leave-one-out. Ainda assim, quatro pares são insuficientes para separar um efeito de tratamento de características específicas das katas. MI e duplicação reforçam a necessidade de múltiplas métricas: uma única observação duplicada altera a leitura, enquanto o MI varia pouco.

6.1 Diferenciais analíticos

- Wilcoxon exato e enumeração das 16 permutações possíveis, adequados ao n pequeno.
- Tamanhos de efeito e estimativas pareadas, além do valor-p.
- Correção de Holm para controlar multiplicidade na RQ3.
- Bootstrap exploratório e análise leave-one-pair-out para visualizar incerteza e sensibilidade.
- Hashes SHA-256 dos CSVs analisados para garantir rastreabilidade dos dados.
- Dashboard unificado com filtros e exportação para inspeção dos trials.

6.2 Integridade e reprodução

Os resultados foram regenerados a partir dos CSVs versionados. No estado utilizado neste relatório, os arquivos possuem os seguintes hashes:

Arquivo	SHA-256
data/trials.csv	09765b538d4b0111aaec52f989267c5d75899e27d170c783a04b179f3bba2b12
data/static_metrics.csv	10b1b82b1d8d3ec2671a367ff9b40183d74ee776a5a2f2b107739bf5726af8f3

7. Conclusão

No contexto controlado deste laboratório, o assistente de IA reduziu de forma grande e consistente o tempo de resolução sem perda funcional detectada. As soluções com IA também foram menores e menos complexas nos quatro pares. Apesar disso, o teste bilateral de RQ1 produziu $p = 0,125$ e nenhuma métrica de RQ3 permaneceu significativa após correção, de modo que as hipóteses nulas não são rejeitadas a 5%.

A conclusão apropriada é contextual: os dados apoiam a utilidade da IA para estas quatro katas e estes participantes, mas não bastam para uma inferência geral. O próximo passo recomendado é replicar o protocolo com mais participantes, ordem plenamente contrabalanceada, identificação exata do modelo, tarefas de maior dificuldade e testes ocultos ou mutacionais.

7.1 Respostas finais

RQ	Resposta final
RQ1	Sim no conjunto observado: todos os pares foram mais rápidos com IA; evidência inferencial ainda insuficiente a 5%.
RQ2	Não houve diferença observável: ambos os tratamentos terminaram com 100% dos testes passando.
RQ3	IA produziu menor LOC e complexidade em todos os pares; MI e duplicação foram inconclusivos e nenhum p ajustado foi significativo.

7.2 Comandos para reprodução

```
python3 -m pytest
python3 analysis/rq1_rq2_analysis.py
python3 analysis/rq3_analysis.py
python3 web/server.py
```

Referências

- [1] WOHLIN, C. et al. Experimentation in Software Engineering. Springer, 2012. Disponível em: <https://doi.org/10.1007/978-3-642-29044-2>
- [2] BASILI, V. R.; CALDIERA, G.; ROMBACH, H. D. The Goal Question Metric Approach. Encyclopedia of Software Engineering, 1994.

- [3] WILCOXON, F. Individual Comparisons by Ranking Methods. Biometrics Bulletin, v. 1, n. 6, p. 80–83, 1945.
Disponível em: <https://doi.org/10.2307/3001968>
- [4] MCCABE, T. J. A Complexity Measure. IEEE Transactions on Software Engineering, v. SE-2, n. 4, p. 308–320, 1976. Disponível em: <https://doi.org/10.1109/TSE.1976.233837>
- [5] RADON. Python tool for code metrics. Documentação oficial. Disponível em: <https://radon.readthedocs.io/>
- [6] KUCHERENKO, D. jscpd: copy/paste detector for programming source code. Disponível em:
<https://github.com/kucherenko/jscpd>
- [7] SCIPY. scipy.stats.wilcoxon — documentação da API. Disponível em:
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html>
- [8] GITHUB. About Projects — documentação oficial. Disponível em: <https://docs.github.com/en/issues/planning-and-tracking-with-projects/learning-about-projects/about-projects>
- [9] BATELLA, C. et al. Análise de Dados Aplicada à Experimentação em Engenharia de Software. Material de apoio, PUC Minas, 2026.