# Mineração de Métricas DORA em Repositórios Open Source Populares

Uma análise de velocidade, estabilidade e sensibilidade das definições operacionais

**Flavio Ferreira; Luidi Cadete Silva**

Engenharia de Software - Laboratório de Experimentação de Software - 21 de outubro de 2026

**Resumo.** Este estudo minera proxies das métricas DORA em 300 repositórios públicos populares que usam GitHub Actions. Releases representam deploys; commits compõem o lead time; e execuções de CI e releases corretivas representam falhas. O pipeline processou 922 candidatos até atingir a amostra final, preservando censura, cache e retomada. A frequência mediana foi 0,422 release/semana, o lead time por release foi 260,12 h, o CFR de CI foi 6,30% e o tempo de recuperação foi 3,54 h. A classificação de referência concentrou 247 repositórios em Medium ou High. Entretanto, trocar o proxy de falha mudou 39,6% das categorias, e a heurística corretiva atingiu F1 máximo de 0,649. Os resultados descrevem o comportamento observável no GitHub, mas não substituem métricas de produção.

**Palavras-chave:** DORA; GitHub Actions; mineração de repositórios; métricas de software; análise de sensibilidade.

## 1. Introdução

As métricas DORA combinam throughput e estabilidade para observar a capacidade de entrega de software. A definição original inclui frequência de deploy, lead time, change failure rate e tempo de recuperação; a nomenclatura e o conjunto evoluíram ao longo dos relatórios DORA [1, 2]. Em repositórios open source, porém, o GitHub não registra diretamente deploys e incidentes em produção. Este trabalho mede aproximações observáveis e testa o quanto as conclusões dependem dessas escolhas.

O objetivo é caracterizar 300 projetos populares com CI/CD e responder sete questões sobre velocidade, falha, recuperação, fatores associados e robustez. As hipóteses foram registradas antes da coleta.

| RQ | Hipótese prévia | Síntese observada |
|---|---|---|
| RQ01 | Cadência predominantemente mensal a semanal | Parcialmente confirmada |
| RQ02 | Lead time por release maior e mais variável | Contradita no agregado |
| RQ03 | CFR de CI maior que CFR por entrega | Contradita; proxy b frágil |
| RQ04 | Recuperação majoritariamente abaixo de 24 h | Confirmada |
| RQ05 | Associação fraca ou inversa entre frequência e CFR | Contradita |
| RQ06 | Características associadas às métricas DORA | Parcialmente confirmada |
| RQ07 | Parte das categorias muda com a definição | Confirmada |

# 2. Metodologia

## 2.1 Delineamento e amostra

O estudo observacional usa dados públicos da API REST, GraphQL e do protocolo Git. A janela inclusiva vai de 01/10/2025 a 30/09/2026. Entraram candidatos com pelo menos 1.000 estrelas, GitHub Actions, cinco releases principais e 50 runs válidos de push no branch padrão. A ordem pseudoaleatória usa semente 42. Dos 922 candidatos processados, 163 não tinham Actions, 393 tinham releases insuficientes, 60 não atingiram o mínimo de runs e seis falharam na coleta; 300 foram incluídos.

## 2.2 Definições operacionais

Deployment frequency é o número de releases principais por semana. O lead time por release usa o commit mais antigo de cada comparação; a variante por commit usa a mediana de todos os commits. O CFR de CI é falhas/(falhas+sucessos). O CFR por entrega identifica uma release falha quando a próxima release, em até sete dias, é classificada como corretiva. O tempo de recuperação liga a primeira falha após um sucesso ao próximo sucesso do mesmo workflow. Episódios abertos permanecem censurados.

## 2.3 Análise estatística

As RQ01-RQ04 usam mediana e IQR. A RQ05 aplica correlação de Spearman. Na RQ06, cinco fatores - estrelas, contribuidores, idade, linguagem e tipo de projeto - são comparados com quatro métricas por Kruskal-Wallis ou Mann-Whitney. Os 20 p-valores recebem correção de Holm [4], e cada teste informa epsilon quadrado ou delta de Cliff. A RQ07 compara quatro cenários por percentual de mudança e kappa de Cohen ponderado.

## 2.4 Validação e consenso

A amostra-ouro contém 60 repositórios e 300 releases. A planilha de Flavio foi produzida com apoio da pré-classificação por IA; a de Luidi foi independente. Logo, as duas não são apresentadas como dois julgamentos humanos cegos. Em divergências, o consenso adotou a avaliação independente de Luidi. Esse desvio do protocolo planejado é reportado como ameaça interna.

| Dimensão | Acordo | Fleiss |
|---|---|---|
| Tipo | 88,3% | 0,827 |
| Entrega | 98,3% | 0,658 |
| Corretiva | 51,0% | -0,163 |

A heurística v1 (patch SemVer ou fix/hotfix/revert) obteve precisão 0,484, recall 0,986 e F1 0,649. Quatro refinamentos produziram F1 entre 0,257 e 0,649; nenhum atingiu 0,70. A v1 foi mantida por melhor F1, com interpretação exploratória.

## 2.5 Engenharia e reprodutibilidade

O pipeline possui paginação, cache comprimido, checkpoint SQLite, retomada, rate limit compartilhado, backoff exponencial e coleta concorrente. A configuração fixa janela, filtros, semente e meta. Os CSVs e o dicionário documentam unidades e fórmulas. A suíte possui 130 testes, executados sem rede, com 95,5% de cobertura do módulo de métricas.

## 2.6 Classificação DORA

Cada métrica recebe Elite, High, Medium ou Low pelos limiares do protocolo. A classe geral é a mediana das quatro notas, arredondada para baixo, e fica ausente se alguma métrica não puder ser calculada.

# 3. Resultados

## 3.1 RQ01 a RQ04 - desempenho de referência

| Métrica | n | Mediana | IQR | Distribuição DORA |
|---|---|---|---|---|
| Deployment frequency | 300 | 0.42 | 0.21 - 0.96 | E 7 \| H 64 \| M 139 \| L 90 |
| Lead time por release | 300 | 260.12 | 75.91 - 998.06 | E 48 \| H 71 \| M 87 \| L 94 |
| Lead time por commit | 300 | 275.78 | 69.78 - 1039.11 | Variante obrigatória |
| CFR de CI | 300 | 6.30% | 2.96% - 12.80% | E 236 \| H 41 \| M 5 \| L 18 |
| CFR por entrega | 299 | 43.48% | 20.00% - 68.72% | Proxy exploratório |
| Tempo de recuperacao | 281 | 3.54 | 1.05 - 11.15 | E 69 \| H 167 \| M 35 \| L 10 |
| Proporcao censurada | 282 | 0.00% | 0.00% - 0.30% | 18 sem proporção |

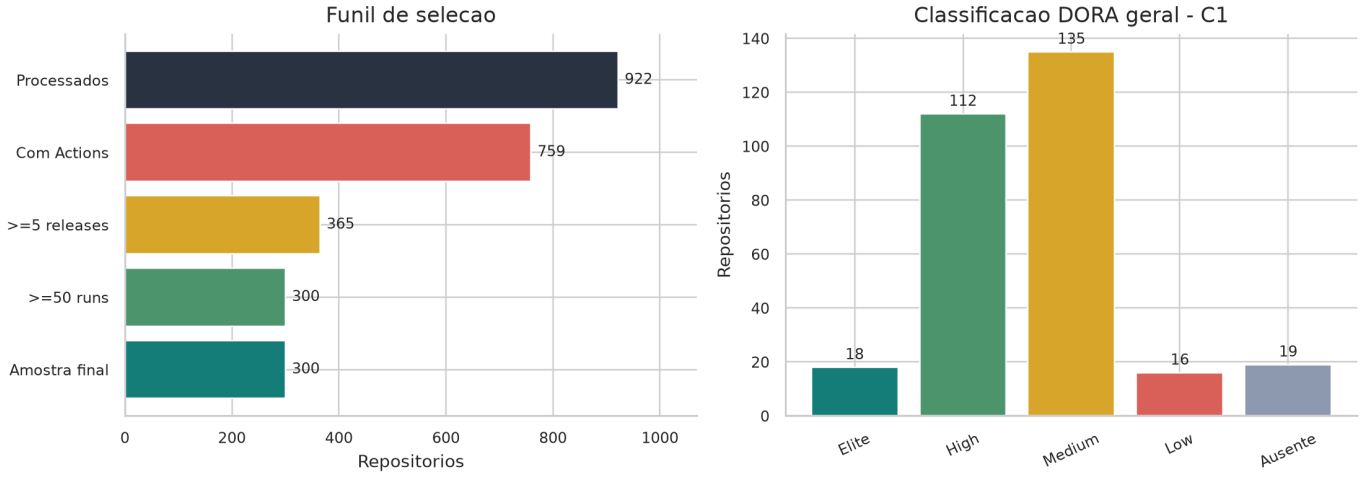



*Figura 1. Funil de seleção e classificação geral de referência C1. Dezenove repositórios ficaram sem classe geral por ausência de recuperação.*

**RQ01.** A mediana de 0,422 release/semana (IQR 0,211-0,964) coloca a categoria Medium como a mais frequente, mas 90 projetos ficaram em Low. **RQ02.** O lead time por release foi 260,12 h (IQR 75,91-998,06), contra 275,78 h (IQR 69,78-1.039,11) por commit. A variante por release foi maior em 178 pares, menor em 121 e igual em um. **RQ03.** O CFR de CI foi 6,30%, muito abaixo do CFR por entrega de 43,48%; a baixa validade da heurística limita a segunda variante. **RQ04.** Entre 281 projetos com recuperação, a mediana foi 3,54 h e 236 (84,0%) ficaram abaixo de 24 h.

## 3.2 RQ05 - frequência e taxa de falha

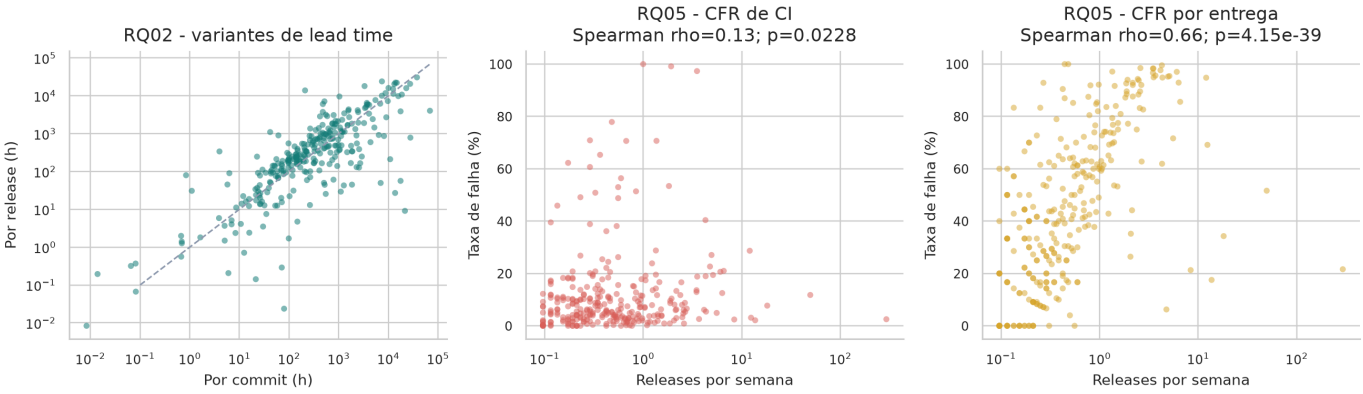



*Figura 2. Dispersões em escala logarítmica. A correlação entre frequência e CFR é fraca para CI e forte para a heurística de releases corretivas.*

O CFR de CI apresentou associação positiva fraca com frequência (rho=0,131; p=0,0228; n=300). O CFR por entrega apresentou associação positiva forte (rho=0,662; p<0,001; n=299). A hipótese de relação fraca ou inversa foi contradita, mas a diferença entre proxies impede interpretar o segundo coeficiente como instabilidade de produção.

## 3.3 RQ06 - fatores associados

| Fator | Métrica | p Holm | Efeito | Magnitude |
|---|---|---|---|---|
| Idade | Lead time | 2.16e-11 | 0.197 | grande |
| Idade | Deployment frequency | 4e-05 | 0.097 | medio |
| Linguagem | Lead time | 4e-05 | 0.115 | medio |
| Linguagem | Deployment frequency | 0.000458 | 0.096 | medio |
| Contribuidores | Lead time | 0.00422 | 0.064 | medio |

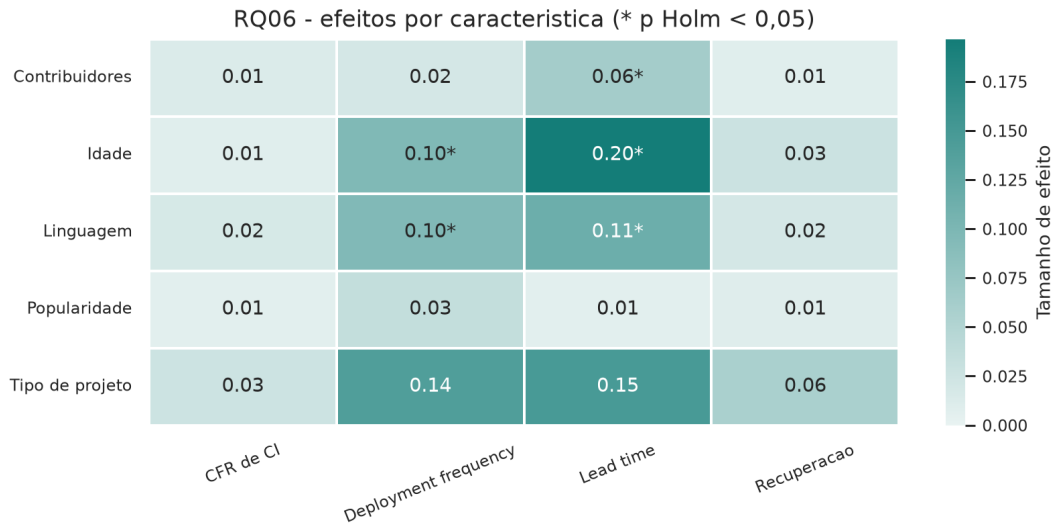



*Figura 3. Mapa de calor dos tamanhos de efeito. O asterisco marca associações que permaneceram significativas após a correção de Holm.*

Idade foi o fator mais forte: projetos no quartil mais novo tiveram frequência mediana de 0,777/semana e lead time de 86,73 h, contra 0,288/semana e 865,61 h no quartil mais antigo. Linguagem se associou a frequência e lead time; contribuidores, apenas ao lead time. Popularidade e tipo de projeto não permaneceram significativos.

### 3.4 RQ07 - análise de sensibilidade

C1 combina lead time por release e CFR de CI; C2, lead time por commit e CFR por release; C3, lead time por commit e CFR de CI; C4, lead time por release e CFR por release. Deployment frequency e recuperação permanecem constantes.

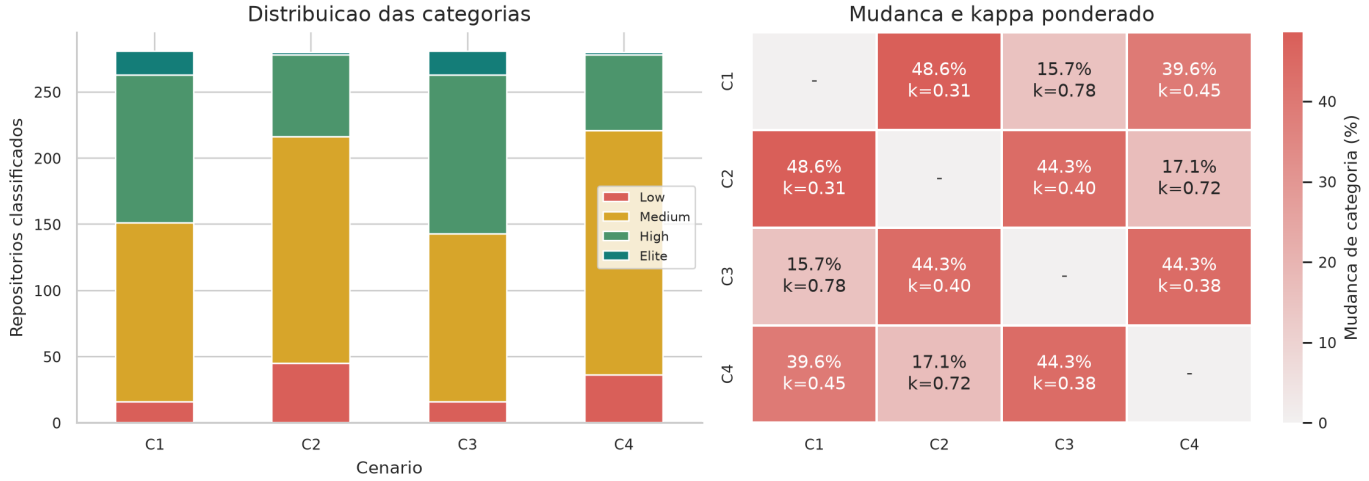



*Figura 4. Distribuição das categorias e comparação par a par. A troca isolada do lead time (C1-C3) muda 15,7%; a troca isolada do CFR (C1-C4), 39,6%.*

A maior diferença ocorreu entre C1 e C2: 48,6% dos 280 casos completos mudaram de categoria, com kappa ponderado 0,305. C1-C3 apresentou 15,7% e kappa 0,785; C1-C4, 39,6% e kappa 0,446. Portanto, a classificação é relativamente robusta à variante de lead time, mas sensível à escolha do proxy de falha.

| Comparação | n | Mudaram | % | Kappa ponderado |
|---|---|---|---|---|
| C1 x C2 | 280 | 136 | 48.6% | 0.305 |
| C1 x C3 | 281 | 44 | 15.7% | 0.785 |
| C1 x C4 | 280 | 111 | 39.6% | 0.446 |
| C2 x C3 | 280 | 124 | 44.3% | 0.404 |
| C2 x C4 | 280 | 48 | 17.1% | 0.717 |
| C3 x C4 | 280 | 124 | 44.3% | 0.380 |

### 3.5 Qualidade dos rótulos e da heurística

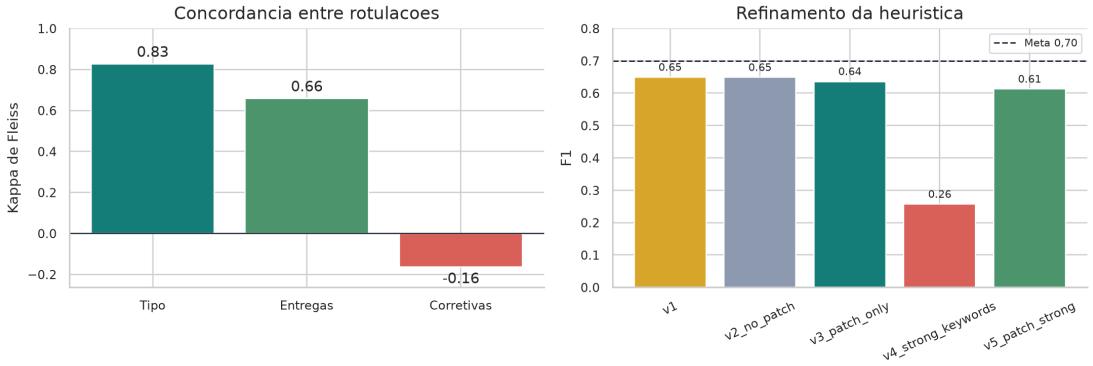



*Figura 5. Concordância das planilhas e desempenho das cinco versões da heurística. Nenhuma versão atingiu a meta de F1=0,70.*

| Versão | Precisão | Recall | F1 | Resultado |
|---|---|---|---|---|
| v1 | 0.484 | 0.986 | 0.649 | refinar |
| v2_no_patch | 0.491 | 0.957 | 0.649 | refinar |
| v3_patch_only | 0.621 | 0.652 | 0.636 | refinar |
| v4_strong_keywords | 0.330 | 0.210 | 0.257 | refinar |
| v5_patch_strong | 0.523 | 0.739 | 0.613 | refinar |

A v1 maximizou recall, porém gerou 145 falsos positivos. A regra somente de patch elevou a precisão para 0,621, mas perdeu 48 corretivas. A ausência de uma versão acima de 0,70 reforça que notas e convenções de versão variam entre projetos.

## 4. Discussão

A amostra combina velocidade moderada, lead time de aproximadamente 11 dias, baixo CFR de CI e recuperação em poucas horas. O perfil geral C1 concentra 247 projetos em Medium ou High. Isso não significa que os projetos possuam o mesmo desempenho em produção: releases de bibliotecas e runs de CI representam fenômenos diferentes de deploys e incidentes de serviços.

A divergência mais importante está na estabilidade. O DORA relata que throughput e estabilidade frequentemente avançam juntos em equipes de alto desempenho [2, 7]. Aqui, frequência e CFR de CI tiveram associação positiva, porém fraca. A associação forte com CFR por entrega parece incompatível com essa leitura, mas depende de uma heurística com baixo acordo e F1. O contraste é evidência sobre a limitação do proxy, não uma refutação direta dos estudos DORA.

Idade, linguagem e contribuidores se associaram a algumas métricas. Projetos mais novos entregaram com maior frequência e menor lead time, mas o delineamento não identifica causa. Ecossistema, arquitetura, governança e estratégia de versionamento podem explicar parte das diferenças.

## 5. Ameaças à validade

### 5.1 Construto

Release não é necessariamente deploy, falha de CI não é falha em produção e patch SemVer não é sinônimo de correção. O F1 máximo de 0,649 e a mudança de 39,6% ao trocar somente o CFR quantificam essa ameaça.

### 5.2 Interna

O estudo não controla maturidade, equipe, domínio ou estratégia de release. Datas de autor podem ser distorcidas por rebase e squash. A planilha de Flavio foi assistida por IA e não constitui avaliação cega; o consenso privilegiou o único julgamento independente nas divergências.

### 5.3 Externa

A amostra inclui apenas projetos públicos, populares, com Actions e volume mínimo de releases e runs. Os resultados não se generalizam automaticamente a projetos privados, pequenos, sem releases formais ou fora do GitHub.

### 5.4 Conclusão

Mediana, IQR e testes não paramétricos reduzem o impacto de assimetria e extremos. A correção de Holm controla comparações múltiplas, mas subgrupos da amostra rotulada têm tamanho reduzido. Ausência e censura foram preservadas, evitando imputação como zero, mas reduzem o número de casos completos.

## 6. Replicação cruzada

Até a consolidação deste artigo, o professor não havia fornecido ao grupo o pipeline sorteado de outra equipe nem a subamostra externa de 30 repositórios. A replicação cruzada e eventuais Issues recebidas, portanto, não foram inventadas. O protocolo preparado registra ambiente limpo, execução apenas pelo README, diferença relativa por métrica, percentual de classes iguais e Issues com evidências. Esta seção deve ser atualizada assim que a atribuição externa for disponibilizada.

## 7. Conclusão

O pipeline caracterizou 300 repositórios com rastreabilidade e resultados reexecutáveis. A definição de referência descreve desempenho majoritariamente Medium/High e recuperação rápida, mas a estabilidade por release não se mostrou confiável. O achado central é metodológico: em mineração de métricas DORA no GitHub, a definição operacional pode alterar substancialmente a categoria final, logo toda comparação deve publicar proxies, censura e sensibilidade.

## 8. Artefatos e links

Repositório: github.com/flaviojuniordev/Software-Measurement-and-Experimentation
GitHub Projects: página de projetos do repositório
Comando de análise: `python -m analysis.analyze_lab03`

## Referências

[1] DORA. *A history of DORA's software delivery metrics*. 2026. https://dora.dev/insights/dora-metrics-history/.

[2] DORA. *DORA's software delivery metrics: the four keys*. https://dora.dev/guides/dora-metrics-four-keys/.

[3] Landis, J. R.; Koch, G. G. The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159-174, 1977. PMID 843571.

[4] Holm, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6, 65-70, 1979. DOI 10.2307/4615733.

[5] Wohlin, C. et al. *Experimentation in Software Engineering*. Springer, 2012. DOI 10.1007/978-3-642-29044-2.

[6] GitHub. *REST API documentation*. https://docs.github.com/en/rest.

[7] DORA. *Accelerate State of DevOps Report 2024*. https://dora.dev/research/2024/dora-report/2024-dora-accelerate-state-of-devops-report.pdf.

## Síntese para apresentação

Os números abaixo concentram a resposta de cada bloco do estudo e podem ser usados como apoio durante a apresentação oral.

| Indicador | Resultado |
|---|---|
| Funil | 922 processados; 300 incluídos |
| Frequência | 0,422 release/semana |
| Lead time | 260,12 h por release |
| CFR de CI | 6,30% |
| Recuperação | 3,54 h; 84% abaixo de 24 h |
| DORA C1 | 18 E; 112 H; 135 M; 16 L; 19 ausentes |
| RQ05 | rho 0,131 (CI); 0,662 (release) |
| RQ06 | idade, linguagem e contribuidores |
| RQ07 | 39,6% mudam ao trocar somente o CFR |
| Validação | melhor F1 = 0,649 |

### Mensagem central

**O pipeline é reexecutável e a amostra é ampla, mas os resultados mostram que uma classificação DORA minerada do GitHub depende fortemente do proxy escolhido. O CFR por release não deve ser apresentado como falha real de produção.**

### Pendência externa

A replicação cruzada só pode ser concluída após o professor informar o pipeline do outro grupo. O protocolo já está preparado no repositório.